UNIVERSITY OF COIMBRA
DEPARTMENT OF INFORMATICS ENGINEERING

FEATURE ENGINEERING FOR MACHINE LEARNING

MUSIC EMOTION RECOGNITION

Predicting emotion from audio, lyrics,
album covers and metadata

Alícia Schiochet e Souza
Luis Nogueira
Sofia

2026
COIMBRA

Calendário de atividade

Calendar

date	event
5 October 2026	brief published
19 October to 27 November 2026	continuous assessment, six weeks. In each PL class, half of the groups hold their three checkpoints in weeks 1, 3 and 5 (from 19 October, 2 November and 16 November), the other half in weeks 2, 4 and 6 (from 26 October, 9 November and 23 November)
23 October 2026	first mini-test, in the TP class
20 November 2026	second mini-test, in the TP class
Saturday, 5 December 2026, 23:59	final delivery, on Inforestudante
last two PL classes of the semester	project defences
normal or resit exam season	third mini-test, at the student's choice

Proposed work schedule

A suggested pace, not a requirement: the nine weeks from the publication of the brief to the final delivery, and the sections to close in each.

week	dates	sections
1	5 to 11 October	1. The dataset, 2. Data understanding, 3. Exploratory analysis
2	12 to 18 October	4.1 Duplicates, 4.2 Missing values, 4.3 Errors
3	19 to 25 October	4.4 Outliers, 4.5 Media, 4.6 The cleaned dataset, 5. Class distribution
4	26 October to 1 November	6. Evaluation of the cleaning, 7. The classifier, 8. Validation protocol
5	2 to 8 November	9. Effect of the preprocessing, 10.1 engineered features
6	9 to 15 November	10.2 to 10.6 learned representations, 11. Selection and transformation
7	16 to 22 November	12. Representation against treatment
8	23 to 29 November	13. Class balancing, 14. Final model and test
9	30 November to 5 December	15. Interpretation, 16. Deployment, 17. Deliverables

Atividade semana 5 a 11 de Outubro - 1. The dataset, 2. Data understanding, 3. Exploratory analysis

1. The dataset

Derived from MERGE Bimodal Complete [1, 2], extended with album covers, and deliberately damaged.

path	content
`audio/`, `lyrics/`, `album_covers/`	the media, one folder per quadrant
`merge_ecac/`	the damaged tables. All work is done on these.
`merge_original/`	the tables as published
`truth/`	every modification made, per cell and per row
`DATA_DICTIONARY.md`	what each column was meant to contain
`IMBALANCE.md`	what was done to the class distribution

The original dataset is public and is therefore provided. `truth/` is not an answer sheet; it is an instrument, used in 6. A cleaned dataset delivered without those measurements is not accepted.

The media files were not modified. The tables were. The original has defects of its own, recorded in no file.

The test partition. `merge_ecac/test_songs.csv` lists 409 songs, 31 % of the dataset, from the partition published with MERGE. Separate them before anything else. Nothing may be fitted on them: no scaler, no imputation, no vocabulary, no selection, no hyperparameter. They are cleaned like the rest and then left untouched until 14.

Provided during the project. Two further resources will be made available:

- the pre-trained models for the learned representations of 10, one per domain that has one;
- a base application for the deployment of 16.

The models provided are a starting point, not an obligation: other pre-trained models may be used instead (10.2).

2. Data understanding

2.1 What is each column supposed to contain? Which are measurements, which are identifiers, which are administrative?

2.2 Do the four sources join one to one? If not, where does it break, and what follows from that?

2.3 From the documentation alone, before computing anything: which columns are suspected of giving away the target? Record the list.

Suggested outputs

- the list of 2.3, dated before any analysis

3. Exploratory analysis

3.1 Describe every column: distribution, range, missing values.

3.2 Which columns are nearly empty? Which are constant? Which measure something other than what their name says?

3.3 Measure how well each column alone predicts the quadrant. Some do it far too well. Which, and by what mechanism did the target reach them?

3.4 Compare 3.3 with the list of 2.3. What proportion was obtainable by reading alone?

3.5 How many songs does each artist have? How many test songs share an artist with the rest of the data? Required in 8.

Suggested outputs

- a table of every column: type, missing rate, association with the target
- the list of columns to discard, with the reason
- a histogram of each numeric column
- a matrix of pairwise scatter plots
- a sorted bar chart of the association of each column with the target

Calendário de atividade

Calendar

date	event
5 October 2026	brief published
19 October to 27 November 2026	continuous assessment, six weeks. In each PL class, half of the groups hold their three checkpoints in weeks 1, 3 and 5 (from 19 October, 2 November and 16 November), the other half in weeks 2, 4 and 6 (from 26 October, 9 November and 23 November)
23 October 2026	first mini-test, in the TP class
20 November 2026	second mini-test, in the TP class
Saturday, 5 December 2026, 23:59	final delivery, on Inforestudante
last two PL classes of the semester	project defences
normal or resit exam season	third mini-test, at the student's choice

Proposed work schedule

A suggested pace, not a requirement: the nine weeks from the publication of the brief to the final delivery, and the sections to close in each.

week	dates	sections
1	5 to 11 October	1. The dataset, 2. Data understanding, 3. Exploratory analysis
2	12 to 18 October	4.1 Duplicates, 4.2 Missing values, 4.3 Errors
3	19 to 25 October	4.4 Outliers, 4.5 Media, 4.6 The cleaned dataset, 5. Class distribution
4	26 October to 1 November	6. Evaluation of the cleaning, 7. The classifier, 8. Validation protocol
5	2 to 8 November	9. Effect of the preprocessing, 10.1 engineered features
6	9 to 15 November	10.2 to 10.6 learned representations, 11. Selection and transformation
7	16 to 22 November	12. Representation against treatment
8	23 to 29 November	13. Class balancing, 14. Final model and test
9	30 November to 5 December	15. Interpretation, 16. Deployment, 17. Deliverables

Atividade semana 1:

5 a 11 de Outubro - 1. The dataset, 2. Data understanding, 3. Exploratory analysis

1. The dataset

Derived from MERGE Bimodal Complete [1, 2], extended with album covers, and deliberately damaged.

path	content
`audio/`, `lyrics/`, `album_covers/`	the media, one folder per quadrant
`merge_ecac/`	the damaged tables. All work is done on these.
`merge_original/`	the tables as published
`truth/`	every modification made, per cell and per row
`DATA_DICTIONARY.md`	what each column was meant to contain
`IMBALANCE.md`	what was done to the class distribution

The original dataset is public and is therefore provided. `truth/` is not an answer sheet; it is an instrument, used in 6. A cleaned dataset delivered without those measurements is not accepted.

The media files were not modified. The tables were. The original has defects of its own, recorded in no file.

The test partition. `merge_ecac/test_songs.csv` lists 409 songs, 31 % of the dataset, from the partition published with MERGE. Separate them before anything else. Nothing may be fitted on them: no scaler, no imputation, no vocabulary, no selection, no hyperparameter. They are cleaned like the rest and then left untouched until 14.

Provided during the project. Two further resources will be made available:

- the pre-trained models for the learned representations of 10, one per domain that has one;
- a base application for the deployment of 16.

The models provided are a starting point, not an obligation: other pre-trained models may be used instead (10.2).

2. Data understanding

2.1 What is each column supposed to contain? Which are measurements, which are identifiers, which are administrative?

2.2 Do the four sources join one to one? If not, where does it break, and what follows from that?

2.3 From the documentation alone, before computing anything: which columns are suspected of giving away the target? Record the list.

Suggested outputs

- the list of 2.3, dated before any analysis

3. Exploratory analysis

3.1 Describe every column: distribution, range, missing values.

3.2 Which columns are nearly empty? Which are constant? Which measure something other than what their name says?

3.3 Measure how well each column alone predicts the quadrant. Some do it far too well. Which, and by what mechanism did the target reach them?

3.4 Compare 3.3 with the list of 2.3. What proportion was obtainable by reading alone?

3.5 How many songs does each artist have? How many test songs share an artist with the rest of the data? Required in 8.

Suggested outputs

- a table of every column: type, missing rate, association with the target
- the list of columns to discard, with the reason
- a histogram of each numeric column
- a matrix of pairwise scatter plots
- a sorted bar chart of the association of each column with the target

Perguntas a serem respondidas:

2.1 What is each column supposed to contain? Which are measurements, which are identifiers, which are administrative?

2.2 Do the four sources join one to one? If not, where does it break, and what follows from that?

2.3 From the documentation alone, before computing anything: which columns are suspected of giving away the target? Record the list.

3.1 Describe every column: distribution, range, missing values.

3.2 Which columns are nearly empty? Which are constant? Which measure something other than what their name says?

3.3 Measure how well each column alone predicts the quadrant. Some do it far too well. Which, and by what mechanism did the target reach them?

3.4 Compare 3.3 with the list of 2.3. What proportion was obtainable by reading alone?

3.5 How many songs does each artist have? How many test songs share an artist with the rest of the data?

Respostas:

2.1 O que cada coluna deve conter? Quais são medições, quais são identificadores e quais são administrativas?

As colunas do dataset têm diferentes tipos de informação. Como identificadores temos `Audio_Song`, `Lyric_Song`, `AllMusic Id`, `AppearancesTrackIDs` e `AppearancesAlbumIDs`. As colunas `AllMusic Extraction Date`, `SampleURL` e `Sample` são mais administrativas.

As principais colunas com valores quantitativos são `Relevance`, `Duration`, `Year`, `LowestYear`, `ActualYear`, `num_Genres` e `num_MoodsAll`, além das colunas de pesos. Já `Artist`, `Title`, `Genres`, `Styles`, `Themes`, `Moods` e `MoodsAll` são informações descritivas sobre cada música.

Por fim, `Quadrant` é a variável que queremos prever, podendo assumir Q1, Q2, Q3 ou Q4.

2.2 As quatro fontes se relacionam de forma um-para-um? Se não, onde essa relação deixa de funcionar e quais são as consequências?

Não existe uma relação completamente 1:1 entre as quatro fontes. Um dos problemas encontrados está no `metadata.csv`, que tem 1348 linhas, mas apenas 1323 músicas diferentes. Isso acontece porque existem 25 linhas duplicadas.

Também existem casos em que não há capa disponível ou em que a mesma capa pode estar associada a mais de uma música. Por causa disso, ao juntar as fontes podem surgir duplicados ou dados em falta. Isso também precisa ser considerado para evitar leakage entre treino e teste.

2.3 Considerando apenas a documentação, antes de realizar qualquer cálculo, quais colunas são suspeitas de revelar a variável alvo? Registre essa lista.

Antes mesmo de fazer os cálculos, as colunas que parecem mais suspeitas de revelar informação sobre o target são `Moods`, `MoodsAll`, `MoodsAllWeights`, `Themes` e `Styles`.

Isso acontece porque essas informações já descrevem características relacionadas com o sentimento ou emoção da música, que também estão relacionadas com a definição dos quadrantes.

3.1 Descreva cada coluna considerando sua distribuição, intervalo de valores e valores ausentes.

O conjunto de treino e desenvolvimento tem 932 linhas. A distribuição do `Quadrant` é:

- Q1: 374 músicas (40,13%)
- Q3: 356 músicas (38,20%)
- Q2: 112 músicas (12,02%)
- Q4: 90 músicas (9,66%)

Existem várias colunas com valores em falta. Os casos mais extremos são `num_Genres` e `num_MoodsAll`, ambas com 98,93% de valores em falta. Também temos `LowestYear` com 34,55%, `ActualYear` com 22,75% e `Duration` com 20,39%.

Também foram encontrados valores estranhos nas amplitudes. Por exemplo, `Duration` vai de -1 até 367000 e `ActualYear` contém valores entre 0 e 9999. `Year` e `LowestYear` também não são apenas anos, pois aparecem como datas e, em alguns casos, datas incompletas.

3.2 Quais colunas estão quase vazias? Quais são constantes? Quais medem algo diferente do que seus nomes indicam?

As colunas que estão praticamente vazias são `num_Genres` e `num_MoodsAll`, com 98,93% dos valores em falta. Não foi encontrada nenhuma coluna totalmente constante.

Algumas colunas também não correspondem exatamente ao que seria esperado pelo nome. `Duration`, por exemplo, possui valores como -1, 0 e 367000, indicando possíveis erros ou diferenças de unidade. `Year` e `LowestYear` também guardam datas, muitas vezes incompletas, e não apenas um ano.

3.3 Meça o quanto cada coluna, individualmente, consegue prever o quadrante. Algumas conseguem prever bem demais. Quais são elas e por qual mecanismo a variável alvo chegou até essas colunas?

As colunas relacionadas com `Moods` apresentam uma relação bastante forte com o `Quadrant`. Isso é um possível caso de target leakage, já que os moods descrevem diretamente características emocionais da música, enquanto os quadrantes também são definidos a partir de características emocionais.

Já variáveis como `Duration` e `Relevance` apresentam bastante sobreposição entre os diferentes quadrantes e, sozinhas, não parecem ter um poder de previsão tão elevado.

3.4 Compare os resultados da questão 3.3 com a lista da questão 2.3. Qual proporção poderia ter sido identificada apenas pela leitura da documentação?

A comparação mostra que boa parte das colunas suspeitas já podia ser identificada apenas lendo a documentação. `Moods`, `MoodsAll`, `MoodsAllWeights`, `Themes` e `Styles` já pareciam problemáticas antes da análise.

Depois da análise, principalmente no caso de `Moods`, foi possível confirmar que realmente existe uma relação forte com o `Quadrant`. Portanto, a documentação já dava uma boa indicação de onde poderia existir target leakage.

3.5 Quantas músicas cada artista possui? Quantas músicas do conjunto de teste compartilham um artista com o restante dos dados?

A maioria dos artistas aparece poucas vezes no dataset. A média é de aproximadamente 1,61 músicas por artista e 627 artistas aparecem apenas uma vez.

Entre os artistas com mais músicas estão Billie Holiday, com 22, Ella Fitzgerald, com 14, The Beatles e Elvis Presley, com 13 cada, e Madonna, com 12.

No conjunto de teste, 204 das 416 linhas pertencem a artistas que também aparecem no conjunto de treino/desenvolvimento. É importante considerar que essas 416 linhas ainda incluem duplicados, enquanto o conjunto de teste possui 409 músicas únicas.

Atividade semana 2:

12 a 18 de Outubro- 4.1 Duplicates, 4.2 Missing values, 4.3 Errors

4. Cleaning

4.1 Duplicates

4.1.1 Identify the identical rows.

4.1.2 No column states which rows are the same recording. Compare four kinds of evidence: the identifier columns, the artist and title, the lyrics, the audio. Do they agree? Which of them establishes that two rows are the same recording?

4.1.3 A remix, an edit or a live version is the same song and a different recording. Is it a duplicate?

4.1.4 Does any recording, or any song, appear on both sides of the test boundary? What does that do to the test score, and what can be done about it without changing the test partition?

4.1.5 How many artists are written in more than one way? What does that do to a cross-validation that places all the songs of each artist in the same fold?

4.1.6 What should be done with each kind of duplicate? Justify.

Suggested outputs

- a table of duplicate groups by kind, with the evidence that established each
- the recordings and songs found on both sides of the test boundary

4.2 Missing values

4.2.1 Classify the missingness mechanism of each column. Justify from the data, not from the column name.

4.2.2 Impute. Why should the method differ between columns?

4.2.3 One column is missing in a way that makes a particular imputation both tempting and wrong. Which, and why?

Suggested outputs

- the mechanism assigned to each column, with its evidence
- a map of missing values across rows and columns, ordered to show the pattern

4.3 Errors

A value that cannot be true. Found by a rule, with no statistics.

4.3.1 Identify the impossible values: sentinel codes, values outside the domain of the column, dates that have not happened.

4.3.2 Identify the values that are impossible only next to another column, where each one alone is unremarkable. Which rule finds them?

Suggested outputs

- a table of the rules applied and how many values each one caught

Perguntas a serem respondidas:

4.1 Duplicates

4.1.1 Identify the identical rows.

4.1.2 No column states which rows are the same recording. Compare four kinds of evidence: the identifier columns, the artist and title, the lyrics, the audio. Do they agree? Which of them establishes that two rows are the same recording?

4.1.3 A remix, an edit or a live version is the same song and a different recording. Is it a duplicate?

4.1.4 Does any recording, or any song, appear on both sides of the test boundary? What does that do to the test score, and what can be done about it without changing the test partition?

4.1.5 How many artists are written in more than one way? What does that do to a cross-validation that places all the songs of each artist in the same fold?

4.1.6 What should be done with each kind of duplicate? Justify.

4.2 Missing values

4.2.1 Classify the missingness mechanism of each column. Justify from the data, not from the column name.

4.2.2 Impute. Why should the method differ between columns?

4.2.3 One column is missing in a way that makes a particular imputation both tempting and wrong. Which, and why?

4.3 Errors

4.3.1 Identify the impossible values: sentinel codes, values outside the domain of the column, dates that have not happened.

4.3.2 Identify the values that are impossible only next to another column, where each one alone is unremarkable. Which rule finds them?

Respostas:

4.1 Duplicados

4.1.1 Identifique as linhas idênticas.

Foram encontradas 50 linhas envolvidas em duplicações exatas, formando 25 pares. Isso significa que existem 25 cópias redundantes no dataset. Após remover uma cópia de cada par, o número de registros passou de 1348 para 1323.

4.1.2 Nenhuma coluna informa quais linhas representam a mesma gravação. Compare quatro tipos de evidência: identificadores, artista e título, letra e áudio. Elas concordam? Qual delas permite afirmar que duas linhas são a mesma gravação?

As quatro evidências não concordam em todos os casos. Depois da remoção dos duplicados exatos, `Audio_Song` e `Lyric_Song` não apresentaram repetições. O `AllMusic Id` apresentou algumas repetições, mas elas estavam relacionadas ao valor `not_found`, então ele não é suficiente para identificar uma gravação.

Artista e título também não são suficientes, pois a mesma música pode ter versões diferentes. A comparação das letras encontrou 18 registros em 9 grupos com letras idênticas, mas isso também ocorreu entre artistas diferentes, como The Beatles e The Isley Brothers em `Twist and Shout`.

Já a comparação do áudio encontrou 4 registros em 2 grupos com arquivos exatamente iguais. Portanto, entre as evidências analisadas, o conteúdo do áudio é a forma mais segura de confirmar que duas linhas representam a mesma gravação.

4.1.3 Um remix, edit ou versão ao vivo é a mesma música, mas uma gravação diferente. Isso deve ser considerado um duplicado?

Não ao nível da gravação. Um remix, versão ao vivo, remasterização ou edit pode representar a mesma música, mas o áudio pode ser diferente.

Um exemplo encontrado foi `Kiss`, de Prince. A versão normal e a versão remasterizada possuem a mesma letra, mas arquivos de áudio diferentes. Por isso, essas versões devem ser mantidas como gravações distintas.

4.1.4 Alguma gravação ou música aparece nos dois lados da divisão entre treino e teste? Qual o efeito disso na avaliação e o que pode ser feito sem alterar a partição de teste?

Foi encontrada uma gravação presente nos dois lados da divisão. As duas entradas de `I F****** Hate You`, do Godsmack, possuem identificadores diferentes, mas o conteúdo do áudio é exatamente igual. Uma estava no treino e a outra no teste.

Isso causa data leakage, pois o modelo pode receber no treino exatamente o mesmo conteúdo que depois aparece no teste, aumentando artificialmente o resultado. Como a partição de teste não pode ser alterada, a solução foi remover do treino o registro `MT0003503243`. Depois disso, não restou nenhum áudio idêntico entre treino e teste.

O notebook confirmou essa sobreposição ao nível da gravação. A sobreposição de uma mesma música em gravações diferentes não foi quantificada separadamente.

4.1.5 Quantos artistas estão escritos de mais de uma forma? Qual o efeito disso em uma validação cruzada que coloca todas as músicas de um artista no mesmo fold?

Após normalizar diferenças de maiúsculas/minúsculas, espaços e outras pequenas variações de escrita, foram encontrados 58 artistas com mais de uma representação no dataset. Alguns exemplos são `Bob Dylan` e `bob dylan`, `Luther Vandross` e `Luther Vandross`, além de `Gloria Estefan` e `Gloria Estefan`.

Se os nomes não forem normalizados antes de uma validação cruzada agrupada por artista, o mesmo artista pode acabar em folds diferentes. Isso quebra a separação desejada e pode deixar o resultado da validação mais otimista do que deveria.

4.1.6 O que deve ser feito com cada tipo de duplicado? Justifique.

As cópias completamente idênticas devem ter apenas uma linha mantida, pois não acrescentam informação. Quando o áudio é exatamente igual, as entradas representam a mesma gravação e também não devem aparecer em lados diferentes da avaliação.

Quando a letra é igual, mas o áudio é diferente, os registros devem ser mantidos, pois podem representar gravações diferentes da mesma música. O mesmo vale para remixes, versões ao vivo e edits.

Variações apenas na escrita de artista ou título devem ser normalizadas, mas não justificam a remoção do registro.

4.2 Valores ausentes

4.2.1 Classifique o mecanismo de valores ausentes de cada coluna. Justifique com base nos dados, e não apenas no nome da coluna.

Os valores ausentes não parecem ocorrer de forma completamente aleatória. Existe uma relação clara com a forma como os dados foram coletados. Por exemplo, os 124 registros da extração `New` não possuem `Moods` nem `Sample`, enquanto esses campos estão presentes nos registros da extração `Old`. Um padrão parecido aparece em `Relevance`, `Year`, `LowestYear`, `Styles`, `StyleWeights`, `SampleURL`, `AppearancesTrackIDs` e `AppearancesAlbumIDs`.

Por isso, essas ausências são mais compatíveis com MAR, pois podem ser explicadas, pelo menos em parte, por uma variável observada como `AllMusic Extraction Date`.

`Genres`, `GenreWeights`, `Themes`, `ThemeWeights`, `MoodsAll`, `MoodsAllWeights`, `ActualYear` e `Duration` também apresentam padrões de ausência associados à disponibilidade de outros metadados, portanto não há evidência suficiente para tratá-los como MCAR.

Já `num_Genres` e `num_MoodsAll` são um caso mais estrutural, pois estão ausentes em aproximadamente 99% dos registros. Nesse caso, praticamente não existe informação suficiente na própria coluna para realizar uma imputação estatística comum.

As colunas essenciais `Audio_Song`, `Lyric_Song`, `Quadrant`, `Artist` e `Title` não possuem valores ausentes.

4.2.2 Como os valores ausentes devem ser imputados? Por que o método deve variar entre as colunas?

Não faz sentido aplicar a mesma imputação em todas as colunas, porque elas representam tipos diferentes de informação.

Em variáveis numéricas, como `Duration`, primeiro é necessário corrigir valores inválidos e diferenças de unidade. Depois disso, uma imputação robusta, como a mediana calculada somente no treino, pode ser utilizada quando necessário.

Em `num_Genres` e `num_MoodsAll`, é melhor reconstruir o valor contando os elementos de `Genres` e `MoodsAll` quando essas informações estiverem disponíveis, em vez de preencher com uma média.

Para campos categóricos ou listas, como `Themes`, `Styles` e `Moods`, preencher com a categoria mais frequente pode criar informação que nunca existiu. Nesses casos, é mais seguro preservar a ausência ou criar uma indicação de valor ausente.

Também é importante que qualquer método de imputação seja ajustado somente no conjunto de treino e depois aplicado ao teste.

4.2.3 Uma coluna possui valores ausentes de uma forma que torna uma determinada imputação tentadora, mas errada. Qual é e por quê?

Um exemplo é `Sample`. Como a coluna funciona praticamente como uma variável binária, seria tentador substituir os valores ausentes por `0`, interpretando que não havia sample disponível.

Porém, os dados mostram que os 124 registros da extração `New` possuem `Sample` ausente. Portanto, a ausência está relacionada ao processo de coleta e não significa necessariamente `Sample = 0`. Preencher automaticamente com zero transformaria falta de informação em uma informação que não foi realmente observada.

4.3 Erros

4.3.1 Identifique os valores impossíveis: códigos sentinela, valores fora do domínio da coluna e datas que ainda não aconteceram.

Foram encontrados vários valores claramente inválidos. Em `Duration`, existem valores `-1`, `0` e `9999`, que funcionam como valores inválidos ou sentinelas. Também existem durações como `367000`, `364000` e `314000`, que estão em uma escala diferente. A comparação mostrou, por exemplo, que `367000` deveria ser `367`, indicando valores armazenados em milissegundos em vez de segundos.

Também foram encontrados valores positivos muito pequenos, como `3.40`, `5.30` e `5.75`, que fazem sentido quando interpretados como minutos e convertidos para segundos.

Em `ActualYear`, aparecem valores impossíveis como `0` e `9999`, além de anos futuros como 2030, 2031, 2032 e outros posteriores ao período dos dados. Esses valores não podem representar corretamente o ano de lançamento.

4.3.2 Identifique valores que só são impossíveis quando comparados com outra coluna, mesmo que cada valor isoladamente pareça normal. Qual regra permite encontrá-los?

A principal regra utilizada foi:

```
LowestYear <= ActualYear
```

Os dois valores podem parecer completamente normais quando observados separadamente, mas `LowestYear` representa o primeiro ano conhecido da música e, portanto, não pode ser posterior a `ActualYear`.

Foram encontradas 38 violações dessa regra entre os registros com anos plausíveis. Um exemplo é `Find out What's Happening`, de Elvis Presley, que apresenta `LowestYear = 1973` e `ActualYear = 1972`. Os dois anos são individualmente possíveis, mas a combinação é impossível. No conjunto original, `ActualYear` é 1973.

Atividade semana 3:

19 a 25 de Novembro- 4.4 Outliers, 4.5 Media, 4.6 The cleaned dataset, 5. Class distribution

4.4 Outliers

A value that is unusual. It may be perfectly true.

4.4.1 Detect outliers with univariate methods. Compare the z-score, the MAD-based modified z-score and Tukey's fences. Which worked better, on which columns, and why do they disagree?

4.4.2 Detect outliers with multivariate methods. Compare k-means and DBSCAN on a numeric feature space. Justify the parameters of each.

4.4.3 Which of the two separates a record that is alone from a small group of records that are together and far from everything else? What does that distinction change in the decision to delete?

4.4.4 At least one record is unremarkable in every column, violates no rule, and is still isolated. Which method found it, and which did not?

4.4.5 Which of the flagged records are extreme and correct, and must survive the filter? How does the criterion keep them?

4.4.6 Errors and outliers are different things. From this dataset, give one example of each: an error that is also an outlier; an error that no univariate method flags and a rule over two columns does; an error that no rule finds and only the joint distribution reveals; an outlier that is not an error.

Suggested outputs

- a table of how many values each univariate criterion flags, per column
- a box plot per numeric column with Tukey's fences, and the values flagged by each of the three univariate criteria marked differently
- the curves used to choose the parameters: the distance to the k-th neighbour for DBSCAN, and the elbow or silhouette for k-means
- the k-means and DBSCAN solutions side by side, in the same two dimensions, with the records each one flags marked
- the record of **4.4.4**, shown in the columns where it stands out
- the four examples of **4.4.6**

4.5 Media

4.5.1 Inspect the covers and the audio. Repeated images, missing covers, excerpts that are not what they claim. Does any of it threaten the evaluation?

Suggested outputs

- a scatter plot of cover width against height
- the distribution of each audio statistic over the corpus

4.6 The cleaned dataset

4.6.1 Apply the decisions of **4.1** to **4.5** and produce the cleaned dataset. The test partition is cleaned by the same rules, fitted on the rest.

4.6.2 What did each decision cost? Rows removed, values replaced, information lost.

Suggested outputs

- the cleaned dataset

- a table of decisions, one row per decision, with its cost

5. Class distribution

5.1 Report the distribution and the ratio between the largest and smallest class.

5.2 Which metrics stop being informative at that ratio?

5.3 What does a majority-class classifier obtain?

Read `IMBALANCE.md` before **13**.

Suggested outputs

- the three numbers above
- a bar chart of class frequencies, before and after cleaning

Perguntas a serem respondidas:

4.4 Outliers

4.4.1 Detect outliers with univariate methods. Compare the z-score, the MAD-based modified z-score andTukey's fences. Which worked better, on which columns, and why do they disagree?

4.4.2 Detect outliers with multivariate methods. Compare k-means and DBSCAN on a numeric feature space. Justify the parameters of each.

4.4.3 Which of the two separates a record that is alone from a small group of records that are together and far from everything else? What does that distinction change in the decision to delete?

4.4.4 At least one record is unremarkable in every column, violates no rule, and is still isolated. Which method found it, and which did not?

4.4.5 Which of the flagged records are extreme and correct, and must survive the filter? How does the criterion keep them?

4.4.6 Errors and outliers are different things. From this dataset, give one example of each: an error that is also an outlier; an error that no univariate method flags and a rule over two columns does; an error that no rule finds and only the joint distribution reveals; an outlier that is not an error.

4.5 Media

4.5.1 Inspect the covers and the audio. Repeated images, missing covers, excerpts that are not what they claim. Does any of it threaten the evaluation?

4.6 The cleaned dataset

4.6.1 Apply the decisions of 4.1 to 4.5 and produce the cleaned dataset. The test partition is cleaned by the same rules, fitted on the rest.

4.6.2 What did each decision cost? Rows removed, values replaced, information lost.

5. Class distribution

5.1 Report the distribution and the ratio between the largest and smallest class.

5.2 Which metrics stop being informative at that ratio?

5.3 What does a majority-class classifier obtain?

Respostas:

4.4 Outliers

4.4.1 Detecte outliers usando métodos univariados. Compare z-score, z-score modificado baseado em MAD e os limites de Tukey. Qual funcionou melhor, em quais colunas e por que eles apresentam resultados diferentes?

Foram comparados os três métodos principalmente nas variáveis `Relevance` e `Duration`.

Em `Relevance`, o z-score identificou 33 outliers, o MAD identificou 69 e Tukey identificou 94. Em `Duration`, foram encontrados 35 pelo z-score, 55 pelo MAD e 162 por Tukey.

A maior diferença ocorreu em `Duration`, pois existem valores em escalas muito diferentes, além de valores como -1, 0, 9999 e valores extremamente altos. Esses extremos afetam bastante a média e o desvio-padrão, fazendo com que o z-score deixe de identificar alguns casos. Por isso, MAD e Tukey foram mais adequados nessa situação, já que são mais robustos à presença de valores extremos.

De qualquer forma, os valores identificados foram tratados apenas como candidatos a outliers e não removidos automaticamente.

4.4.2 Detecte outliers usando métodos multivariados. Compare k-means e DBSCAN em um espaço de atributos numéricos. Justifique os parâmetros escolhidos.

Para a análise multivariada foram utilizadas inicialmente `Relevance` e `Duration`, com `RobustScaler` para diminuir a influência dos valores extremos.

No k-means foi escolhido `k = 4` com base principalmente na análise da curva do cotovelo. Como o k-means não possui uma categoria própria para outliers, foram considerados candidatos os 5% dos registros com maior distância em relação ao centro do seu cluster. Dessa forma, 32 registros foram sinalizados.

No DBSCAN foram utilizados `min_samples = 4` e `eps = 2.0`. O valor de `eps` foi escolhido observando a curva da distância ao quarto vizinho, enquanto `min_samples = 4` foi usado para definir a quantidade mínima de pontos necessária para formar uma região densa. O DBSCAN classificou 39 registros como ruído.

Dos registros encontrados, 27 foram sinalizados pelos dois métodos. A principal diferença é que o k-means sempre atribui cada observação a algum cluster, enquanto o DBSCAN consegue classificar diretamente observações em regiões de baixa densidade como ruído.

4.4.3 Qual dos dois métodos consegue diferenciar um registro isolado de um pequeno grupo de registros que estão juntos, mas distantes dos demais? O que essa diferença muda na decisão de excluir os registros?

O DBSCAN é mais adequado para fazer essa distinção. Um ponto realmente isolado pode ser classificado como ruído, enquanto um pequeno grupo distante dos demais ainda pode formar seu próprio cluster caso exista densidade suficiente entre seus elementos.

Essa diferença é importante porque um pequeno grupo distante não deve ser automaticamente eliminado. Ele pode representar uma subpopulação real dos dados. Já um registro completamente isolado merece uma investigação maior antes de decidir se deve ser mantido ou removido.

4.4.4 Pelo menos um registro não apresenta nada de anormal quando cada coluna é analisada separadamente, não viola nenhuma regra, mas ainda assim está isolado. Qual método o encontrou e quais não encontraram?

Um exemplo encontrado foi `Let Love Rule`, de Lenny Kravitz. A música possui `Arousal = 0.465` e `Valence = 0.57875`, valores próximos do centro de suas distribuições. O Arousal está aproximadamente no percentil 43 e a Valence no percentil 53.

Por isso, z-score, MAD e Tukey não identificaram o registro como outlier. Porém, o DBSCAN conseguiu identificá-lo como ruído ao analisar a combinação entre Arousal e Valence, pois existe pouca densidade de observações naquela região.

Isso mostra que um registro pode parecer normal em cada variável separadamente, mas ser incomum quando as variáveis são analisadas em conjunto.

4.4.5 Quais registros sinalizados são extremos, mas corretos, e precisam ser mantidos? Como o critério utilizado evita que sejam removidos?

Um exemplo claro é `Happy`, de Pharrell Williams, com `Arousal = 0.975` e `Valence = 0.9875`. A música foi sinalizada como outlier por possuir um Arousal muito alto.

Apesar disso, os dois valores estão dentro do intervalo válido entre 0 e 1 e os mesmos valores aparecem no conjunto de dados original. Portanto, não existe evidência de erro e o registro deve ser mantido.

O critério utilizado foi não remover um registro apenas porque ele foi sinalizado estatisticamente. Primeiro foi verificado se o valor era possível e se existia alguma evidência de erro. Assim, valores raros, mas legítimos, puderam ser preservados.

4.4.6 Erros e outliers são coisas diferentes. Dê um exemplo do dataset para cada caso: um erro que também é outlier; um erro que nenhum

método univariado detecta, mas uma regra entre duas colunas detecta; um erro que nenhuma regra encontra e apenas a distribuição conjunta revela; e um outlier que não é erro.

Erro que também é outlier: `I Gotta Right to Sing the Blues`, de Ella Fitzgerald. O valor de `Relevance` foi alterado de aproximadamente 1.041 para 1.84. Nesse caso, o valor é estatisticamente extremo e também corresponde a um erro real.

Erro encontrado por uma regra entre duas colunas: `Find out What's Happening`, de Elvis Presley. O registro possui `LowestYear = 1973` e `ActualYear = 1972`. Os dois valores são normais separadamente, mas violam a regra `LowestYear <= ActualYear`. No conjunto original, `ActualYear` é 1973.

Erro revelado pela distribuição conjunta: `Epistle to Derroll`, de Donovan. `LowestYear` foi alterado de 1967 para 1962, enquanto `ActualYear` continua sendo 1967. Os dois valores são possíveis e a regra anterior continua sendo respeitada. Porém, a análise conjunta mostra que `LowestYear` e `ActualYear` normalmente coincidem, tornando essa combinação incomum.

Outlier que não é erro: `Happy`, de Pharrell Williams. Seus valores de Arousal e Valence são extremos, mas válidos e iguais aos encontrados no conjunto original.

4.5 Mídia

4.5.1 Inspecione as capas e os arquivos de áudio. Existem imagens repetidas, capas ausentes ou trechos de áudio que não correspondem ao que deveriam? Algum desses problemas ameaça a avaliação?

Foram encontrados 2216 arquivos de áudio e 2019 capas. Portanto, existem 197 músicas com áudio, mas sem uma capa correspondente.

Nas capas também foram encontrados 182 grupos de imagens exatamente repetidas, envolvendo 427 arquivos. Além disso, as dimensões das imagens variam, embora a maioria seja aproximadamente quadrada.

No áudio, todos os 2216 arquivos puderam ser analisados e nenhum registro utilizado no treino ou teste ficou sem áudio. Foram encontrados 4 grupos de áudios exatamente repetidos, envolvendo 8 arquivos.

Essas repetições podem prejudicar a avaliação caso o mesmo conteúdo apareça no treino e no teste, pois o modelo poderia receber durante o treinamento algo praticamente igual ao que depois será usado para avaliá-lo. A sobreposição de áudio encontrada entre treino e teste foi tratada anteriormente removendo o registro correspondente do treino.

A inspeção realizada verificou presença, tamanho e igualdade exata dos arquivos. Ela não verificou manualmente o conteúdo de todos os áudios para confirmar se cada trecho corresponde semanticamente à música indicada.

4.6 Dataset limpo

4.6.1 Aplique as decisões das seções 4.1 a 4.5 e produza o dataset limpo. A partição de teste deve ser limpa usando as mesmas regras, ajustadas somente no restante dos dados.

Após a limpeza, foram gerados os arquivos `train_clean_final.csv` e `test_clean_final.csv`.

O conjunto final de treino possui 913 registros e 27 atributos, enquanto o teste possui 409 registros e também 27 atributos. Não existem valores ausentes nas colunas essenciais `Audio_Song`, `Lyric_Song` e `Quadrant`.

Também não existem duplicados exatos nos conjuntos finais e a sobreposição de `Audio_Song` entre treino e teste é zero.

As decisões que dependem dos dados foram tomadas utilizando o conjunto de treino, preservando o teste como conjunto separado para a avaliação posterior.

4.6.2 Qual foi o custo de cada decisão? Quantas linhas foram removidas, quantos valores foram substituídos e quanta informação foi perdida?

A remoção dos duplicados exatos eliminou 25 cópias redundantes do conjunto inicial. Além disso, foi removido 1 registro do treino porque seu áudio também estava presente no conjunto de teste.

Os outliers legítimos não foram removidos, então não houve perda de registros por esse motivo. As 197 músicas sem capa também foram mantidas, mas para elas a informação visual não está disponível.

Os áudios duplicados foram identificados para controle e não removidos automaticamente, exceto no caso em que havia sobreposição entre treino e teste.

Na tabela de custos utilizada no notebook não foram contabilizadas substituições automáticas de valores. A estratégia priorizou evitar a remoção ou alteração de informações quando não existia evidência suficiente de erro.

5. Distribuição das classes

5.1 Informe a distribuição das classes e a razão entre a maior e a menor classe.

Após a limpeza, o conjunto de treino possui 913 registros:

- Q1: 366 registros (40,09%)
- Q2: 111 registros (12,16%)
- Q3: 347 registros (38,01%)
- Q4: 89 registros (9,75%)

A maior classe é Q1, com 366 registros, e a menor é Q4, com 89. A razão entre elas é aproximadamente **4,11:1**.

No teste, a distribuição é Q1 = 159, Q2 = 56, Q3 = 153 e Q4 = 41.

5.2 Quais métricas deixam de ser informativas com esse nível de desequilíbrio?

A principal métrica que deixa de ser suficiente sozinha é a **accuracy**. Como algumas classes aparecem aproximadamente quatro vezes mais do que outras, um modelo pode obter uma accuracy aparentemente boa simplesmente favorecendo as classes mais frequentes.

Por isso, é melhor analisar também métricas como **macro F1-score, balanced accuracy e recall por classe**. Elas permitem observar melhor o desempenho nas classes minoritárias e evitam que o resultado seja dominado apenas pelas classes maiores.

5.3 Qual resultado é obtido por um classificador que sempre prevê a classe majoritária?

A classe majoritária é Q1, com 366 dos 913 registros de treino.

Um classificador que simplesmente previsse Q1 para todas as músicas teria aproximadamente **40,09% de accuracy**, mesmo sem aprender nenhuma diferença entre os quadrantes.

Por isso, esse valor funciona como um baseline importante: um modelo com accuracy próxima de 40% não necessariamente aprendeu algo útil sobre o problema.

Atividade semana 4:

26 a 01 de Novembro- 6. Evaluation of the cleaning, 7. The classifier, 8. Validation protocol

6. Evaluation of the cleaning

6.1 Using `truth/`, evaluate the detectors of 4 as classifiers. What was found, what was missed, what was flagged and had never been damaged?

6.2 Take ten records flagged by a detector and absent from `truth/`. For each: an error, a legitimate extreme, or a member of a real sub-population?

6.3 Compare imputation methods on one column against the real values.

6.4 What do these numbers allow one to conclude about the columns for which no ground truth exists?

Suggested outputs

- found and missed, per defect family
- the verdict on each of the ten records of 6.2
- a bar chart of recall by defect family
- a precision-recall curve with the chosen operating point marked

7. The classifier

7.1 Build the simplest pipeline that runs end to end: the numeric columns of `metadata.csv` as read, median imputation, no scaling, kNN, five-fold cross-validation stratified by class, on the 914 songs outside the test partition.

7.2 Run it with k = 5, then with k chosen properly. Report both, as accuracy and macro F1. Where they disagree, why?

A condition. Every comparison from here on is between two conditions. A condition is never a pipeline with a hyperparameter frozen in it; it is the best that pipeline achieves:

- hyperparameters are chosen inside each fold, on the training part of that fold alone, and the chosen model is scored on the part held out;
- the same grid is used in every condition. At minimum: k over the odd values from 1 to 31, two distance functions, uniform and distance weighting;
- everything fitted from data is fitted inside the fold. Imputer, scaler, encoder, vocabulary, reduction, selection, resampling;
- the score is macro F1, as the mean over folds with its spread. Accuracy is reported alongside.

7.3 Why does choosing k on the same folds that are then reported produce a number that does not survive the test partition?

7.4 When a change to the pipeline moves the best k, what does that say about the feature space?

Suggested outputs

- the baseline score
- the hyperparameters chosen by every condition reported from here on

8. Validation protocol

> **Experiment 1.** The same pipeline, scored two ways: five-fold cross-validation stratified by class, and five-fold cross-validation with all the songs of each artist in the same fold, so that no artist appears on both sides of a split (artist-disjoint).

8.1 Report both estimates and the gap.

8.2 The two estimates answer two different questions. Which question does each answer?

8.3 The test partition was not built by artist. Given **3.5**, which of the two estimates should it reproduce, and why?

8.4 Which of the two questions will the application of **16** face? Which protocol is used for the rest of the project? Justify.

Suggested outputs

- both estimates and their gap
- the protocol used from here on

Perguntas a serem respondidas:

6. Evaluation of the cleaning

6.1 Using truth/, evaluate the detectors of 4 as classifiers. What was found, what was missed, what was flagged and had never been damaged?

6.2 Take ten records flagged by a detector and absent from truth/. For each: an error, a legitimate extreme,or a member of a real sub-population?

6.3 Compare imputation methods on one column against the real values.

6.4 What do these numbers allow one to conclude about the columns for which no ground truth exists?

7. The classifier

7.1 Build the simplest pipeline that runs end to end: the numeric columns of metadata. csv as read, median imputation, no scaling, kNN, five-fold cross-validation stratified by class, on the 914 songs outside the test partition.

7.2 Run it with k = 5, then with k chosen properly. Report both, as accuracy and macro F1. Where they disagree, why?

A condition. Every comparison from here on is between two conditions. A condition is never a pipeline with
a hyperparameter frozen in it; it is the best that pipeline achieves:

7.3 Why does choosing k on the same folds that are then reported produce a number that does not survive the test partition?

7.4 When a change to the pipeline moves the best k, what does that say about the feature space?

8. Validation protocol

Experiment 1. The same pipeline, scored two ways: five-fold cross-validation stratified by class, and five- fold cross-validation with all the songs of each artist in the same fold, so that no artist appears on both sides of a split (artist-disjoint).

8.1 Report both estimates and the gap.

8.2 The two estimates answer two different questions. Which question does each answer?

8.3 The test partition was not built by artist. Given 3.5, which of the two estimates should it reproduce, and why?

8.4 Which of the two questions will the application of 16 face? Which protocol is used for the rest of the project? Justify.

.

.

.

.

Atividade semana 5:

02 a 08 de Novembro- 9. Effect of the preprocessing, 10.1 engineered features

9. Effect of the preprocessing

> **Experiment 2.** The pipeline of 7, adding one step at a time: raw; cleaned; cleaned and imputed per column; cleaned, imputed and scaled. Every step tuned as 7 requires.

9.1 Report the score after each step.

9.2 Which step moved the score most? Why is that step decisive for kNN in particular?

9.3 Does the order of the steps matter? Give a case from this dataset where it does.

9.4 Repeat the cleaning step once per defect family of 4. Which part of the cleaning paid for itself?

9.5 If a step lowered the score, what does that mean, and is it kept anyway?

Suggested outputs

- a table with one row per step and one row per defect family: score, difference, chosen k

10. Representations

10.1 Extract engineered features from each domain. The choice of features and of tools is free. Audio, lyrics and cover have at least 10 columns each, covering at least:

domain	groups covered
audio	4 of: melody, harmony, rhythm, dynamics, tone colour, expressivity, texture, form [5]
lyrics	3 of: content, style, song structure, semantics [6]
cover	3 of: colour, texture, composition, content [7]

The metadata contributes the columns kept in 3.

A feature is one column: the mean and the standard deviation of a descriptor are two. Each feature is documented with what it measures, how it is computed and with which parameters, and the axis of Figure 1 it is expected to inform: valence, arousal or neither. Features computed the same way are documented together. Does the data support the expected axis? Compare it with the association of each feature with valence and with arousal, on the training songs.

Perguntas a serem respondidas:

9.2 Which step moved the score most? Why is that step decisive for kNN in particular?
9.3 Does the order of the steps matter? Give a case from this dataset where it does.

9.4 Repeat the cleaning step once per defect family of 4. Which part of the cleaning paid for itself?

9.5 If a step lowered the score, what does that mean, and is it kept anyway?

.

10. Representations

10.1 Extract engineered features from each domain. The choice of features and of tools is free. Audio, lyrics and cover have at least 10 columns each, covering at least: domain, audio, lyrics, cover

The metadata contributes the columns kept in 3.

A feature is one column: the mean and the standard deviation of a descriptor are two. Each feature is documented with what it measures, how it is computed and with which parameters, and the axis of Figure 1 it is expected to inform: valence, arousal or neither. Features computed the same way are documented together. Does the data support the expected axis? Compare it with the association of each feature with valence and with arousal, on the training songs.

Atividade semana 6:

09 a 15 de Novembro- 10.2 to 10.6 learned representations, 11. Selection and transformation

10.2 Extract learned representations with pre-trained models, at least one for each of audio, lyrics and cover. The models provided may be used, or others chosen by the group. A model chosen by the group is identified by name, version and source, is used without further training on this dataset, and must run in the base application of **16**.

10.3 What was each model trained to do? How far is that task from recognising emotion?

10.4 Each model expects its input in a particular form. What does each one expect, and what had to be done to the audio, the lyrics and the covers to meet it? What was lost in the process?

10.5 The tag columns of the metadata are lists. How are they encoded, and which of them can be used at all?

10.6 How was it guaranteed that nothing was fitted on the test partition?

Suggested outputs

- the feature table of **10.1**: one row per feature or group of features, with its domain, group, computation and expected axis
- one matrix per domain and per family, with its dimension and the cost of producing it
- for each model used, the input it expects and what was done to the data to meet it
- the distributions by class of the features that separate best
- a correlation matrix per domain

11. Selection and transformation

Two ways of reducing a representation. **Selected**: a subset of the original features. **Transformed**: new features built from all of them.

11.1 Select with a filter, a wrapper and an embedded method, on the engineered features of the training songs. Do they agree? Which features survive all three?

11.2 The embedded method ranks features with a model other than kNN. Does that matter?

11.3 One selection method is carried into **12**, where it is fitted again inside every fold of every cell. Which one, and why? What would the wrapper cost there?

Perguntas a serem respondidas:

10.2 Extract learned representations with pre-trained models, at least one for each of audio, lyrics and cover. The models provided may be used, or others chosen by the group. A model chosen by the group is identified by name, version and source, is used without further training on this dataset, and must run in the base application of 16.

10.3 What was each model trained to do? How far is that task from recognising emotion?

10.4 Each model expects its input in a particular form. What does each one expect, and what had to be done to the audio, the lyrics and the covers to meet it? What was lost in the process?

10.5 The tag columns of the metadata are lists. How are they encoded, and which of them can be used at all?

10.6 How was it guaranteed that nothing was fitted on the test partition?

11. Selection and transformation

11.1 Select with a filter, a wrapper and an embedded method, on the engineered features of the training songs. Do they agree? Which features survive all three?

11.2 The embedded method ranks features with a model other than kNN. Does that matter?

11.3 One selection method is carried into 12, where it is fitted again inside every fold of every cell. Which one, and why? What would the wrapper cost there?

Atividade semana 7:

16 a 22 de Novembro- 12. Representation against treatment

12. Representation against treatment

> **Experiments 3 and 4.** One grid. Every cell is a condition, and every cell has the same dimension, for four or more values of it, three among them. LDA cannot go beyond three, so its column is filled at three only.

	selected	PCA	LDA
engineered			
learned			
both			

> Experiment 3 reads the grid by rows: engineered against learned, under the same treatment. Experiment 4 reads it by columns: selected against transformed, and PCA against LDA, for the same representation.

12.1 Which representation wins, under which treatment, at which dimension? Does the winner change with the treatment?

12.2 Does the best treatment depend on the representation? Why might it?

12.3 How few dimensions can be kept before the score moves?

12.4 Joining two representations lets the larger one dominate the distance, and the variance that PCA sees. How were they joined, and how was that prevented?

12.5 Which distance suits each representation, and why?

12.6 Repeat the best cell once per domain. Which domain carries the signal?

12.7 Report the cost of each cell. At what price is the cheaper option still preferable?

Suggested outputs

- the grid, at every dimension tested
- a plot of score against dimension, one line per cell
- the cell carried into the final pipeline

Perguntas a serem respondidas:

12.1 Which representation wins, under which treatment, at which dimension? Does the winner change with the treatment?

12.2 Does the best treatment depend on the representation? Why might it?

12.3 How few dimensions can be kept before the score moves?

12.4 Joining two representations lets the larger one dominate the distance, and the variance that PCA sees. How were they joined, and how was that prevented?

12.5 Which distance suits each representation, and why?

12.6 Repeat the best cell once per domain. Which domain carries the signal?

12.7 Report the cost of each cell. At what price is the cheaper option still preferable?

Atividade semana 8:

23 a 29 de Novembro- 13. Class balancing, 14. Final model and test

13. Class balancing

> **Experiment 5.** Four conditions: untreated, SMOTE, one other remedy, and the training data with the subsampled classes restored from `merge_original/` and cleaned like the rest, which is the ceiling. Nothing is restored into the test partition.

13.1 What proportion of the gap to the ceiling does each remedy recover?

13.2 The two subsampled classes are equally rare and do not behave the same way. Explain the difference, per class and not on the average.

13.3 SMOTE builds its samples with nearest neighbours too. What does that imply for a classifier that then looks for nearest neighbours?

13.4 Resampling applied in the wrong place inflates the result. Demonstrate it.

Suggested outputs

- a table of the four conditions, with per-class recall
- the synthetic samples among the real ones, in two dimensions

14. Final model and test

14.1 Collect the five experiments in one table.

experiment	condition A	condition B	score A	score B	difference	hyperparameters	kept

For experiments 3 and 4, one row per reading of the grid: the best row against the next, and the best column against the next.

14.2 Build the final pipeline from the decisions that earned their place. Choose its hyperparameters with the protocol of **8** on the 914 songs, refit on all of them, and score once on the test partition.

14.3 Report the test score with an interval.

14.4 Compare it with the best validation score. Three things separate them: the choice of the best among many conditions, the artists shared between the test partition and the training data, and the size of the test partition. In which direction does each push, and which dominates here?

14.5 Report per-class precision, recall and F1, and a confusion matrix. Which pair of classes is confused, and would a person confuse the same pair?

14.6 Compare against the majority-class baseline, against **7**, and against the published results for this dataset. Is that last comparison legitimate?

14.7 The smallest class has 41 songs in the test partition. What do the per-class intervals permit concluding?

Suggested outputs

- the table of **14.1**
- the test score with its interval, and the analysis of **14.4**
- a confusion matrix
- score against k, for the baseline and the final pipeline on the same axes
- a single chart of the five experiments

Perguntas a serem respondidas:

13.1 What proportion of the gap to the ceiling does each remedy recover?

13.2 The two subsampled classes are equally rare and do not behave the same way. Explain the difference, per class and not on the average.

13.3 SMOTE builds its samples with nearest neighbours too. What does that imply for a classifier that then looks for nearest neighbours?

13.4 Resampling applied in the wrong place inflates the result. Demonstrate it.

14. Final model and test

14.4 Compare it with the best validation score. Three things separate them: the choice of the best among many conditions, the artists shared between the test partition and the training data, and the size of the test partition. In which direction does each push, and which dominates here?

14.5 Report per-class precision, recall and F1, and a confusion matrix. Which pair of classes is confused, and would a person confuse the same pair?

14.6 Compare against the majority-class baseline, against 7, and against the published results for this dataset. Is that last comparison legitimate?

14.7 The smallest class has 41 songs in the test partition. What do the per-class intervals permit concluding?

.

.

.

.

Atividade semana 9:

30 a 05 de Dezembro- 15. Interpretation, 16. Deployment, 17. Deliverables

15. Interpretation

15.1 Which features does the model use? Use a model-agnostic method.

15.2 Explain two songs classified correctly and two classified incorrectly, through their nearest neighbours.

15.3 Does the model agree with 3? If a feature identified there as leakage is still present, find it.

Suggested outputs

- the ranking of **15.1**, as a chart showing the direction of each effect where it exists
- the four explanations of **15.2**

16. Deployment

16.1 Integrate the final pipeline into the base application provided. Input: metadata, an audio file, a lyrics file, a cover image. Output: the predicted quadrant and a confidence.

16.2 What does the base application expect from a pipeline? What had to change in the pipeline to meet it?

16.3 Every transformation of the training pipeline runs again here, in the same order, with the same fitted parameters. Demonstrate it: ten songs from the test partition through the application, predictions identical to those of the notebook.

16.4 Which of the metadata fields used by the model would exist for a song that is not yet in any catalogue? What follows for the model?

16.5 What does the application do when a field is missing? Justify.

Suggested outputs

- the base application running the final pipeline
- the table of **16.3**: ten songs, two predictions each

17. Deliverables

The suggested outputs of each section are a guide, not a checklist. What is required is the following:

- the report, answering the numbered questions and containing the grid of **12** and the table of **14.1**: a document of at most twelve pages, or the notebooks themselves, in the form described under *Work and delivery*;
- the code, as Python files or notebooks, with its dependencies listed, runnable from start to end in a clean environment with fixed random seeds;
- the base application with the final pipeline integrated, and instructions to run it.

18. Assessment

The practical component. The project and the mini-tests form the practical component of the course: 40 % of the final grade, 8 out of 20. The project is worth 5, the mini-tests 3. The minimum is 35 % of the component, the project and the mini-tests taken together.

The defence. Individual and mandatory. Its result, a percentage, multiplies the mark of the project. Each student reaches it in one of two ways:

- continuous assessment: three checkpoints in the PL classes, worth 25 % of the defence each, and the final defence for the remaining 25 %;
- the final defence alone, for a student who does not take the checkpoints.

The checkpoints can be recovered: the first and the second at the following checkpoint, the third at the final defence.

The mini-tests. Three, multiple choice, 20 minutes each. The best two count. Wrong answers are penalised, blank answers are not. The first two are held in TP classes on fixed dates. The third is held in the exam season, normal or resit, at the student's choice; a student who takes it in the normal season cannot repeat it in the resit season.

Additional oral defence. At any moment, any student may be asked for an individual oral defence on any component of the assessment. Its result prevails over the mark previously obtained in that component.

The mark of the project.

criterion	weight
Data preparation and its justification	20%
Features, representations, selection	20%
Experimental protocol and honest evaluation	20%
Interpretation and critical reading of results	20%
Deployment	10%
Report and code	10%

Marks are earned by the reasoning, not by the accuracy. A decision that lowered the score and was kept for a good reason is worth more than one that raised it and cannot be explained. Two groups with the same final score do not necessarily receive the same mark.

Any result obtained by fitting on the test partition, at any stage, voids the section it belongs to.

Use of AI in the preparation of this brief

A generative AI model, Claude Opus 5.5, was used in two parts of the preparation of this brief: to create the damaged version of the dataset described in 1, and to make textual adjustments to this document. All of its content is the responsibility of the teaching staff of the course.

Perguntas a serem respondidas:

15. Interpretation

15.1 Which features does the model use? Use a model-agnostic method.

15.2 Explain two songs classified correctly and two classified incorrectly, through their nearest neighbours.

15.3 Does the model agree with 3? If a feature identified there as leakage is still present, find it.

16. Deployment
16.1 Integrate the final pipeline into the base application provided. Input: metadata, an audio file, a lyrics file, a cover image. Output: the predicted quadrant and a confidence.

16.2 What does the base application expect from a pipeline? What had to change in the pipeline to meet it?

16.3 Every transformation of the training pipeline runs again here, in the same order, with the same fitted parameters. Demonstrate it: ten songs from the test partition through the application, predictions identical to those of the notebook.

16.4 Which of the metadata fields used by the model would exist for a song that is not yet in any catalogue? What follows for the model?

16.5 What does the application do when a field is missing? Justify.

.

.

.

.

.